

Laboratorio 5: Minería de Textos y Clasificación de Tweets sobre Desastres Naturales

Entrega Parcial: Avances de Exploración, Preprocesamiento y Modelado Preliminar

Javier Eduardo España (23204)

Angel Esteban Esquit (23249)

Bryan Gabriel Aguilar (23354)

*Departamento de Ciencias de la Computación, Universidad del Valle de Guatemala
CC3084 - Data Science*

27 de agosto de 2026

Resumen

En el presente informe de avance se documentan los resultados del procesamiento de lenguaje natural y minería de texto sobre el conjunto de datos *Natural Language Processing with Disaster Tweets* de Kaggle. Se detallan las dimensiones y características estructurales del dataset, el análisis exploratorio de datos (EDA), el comportamiento de atributos como palabras clave y ubicaciones, y la distribución de longitudes de texto. Asimismo, se expone de forma minuciosa la metodología de preprocesamiento, el tratamiento diferenciado de entidades, la generación de n-gramas (unigramas, bigramas y trigramas), la visualización de frecuencias léxicas mediante nubes de palabras e histogramas, y el análisis de la necesidad de contexto. Finalmente, se diseñan, entrenan y evalúan cuatro arquitecturas preliminares de clasificación (*Multinomial Naive Bayes*, *Complement Naive Bayes*, *Logistic Regression* y *Linear SVM*) sobre representaciones TF-IDF que incorporan unigramas y bigramas, discutiendo su desempeño y estableciendo la base para la entrega final.

1. Introducción

La rápida proliferación de redes sociales, en particular plataformas de microblogging como X (anteriormente Twitter), ha transformado la comunicación en situaciones de emergencia. Durante eventos catastróficos (terremotos, inundaciones, incendios forestales), los usuarios publican testimonios en tiempo real que son de alto valor para agencias de respuesta y organizaciones de ayuda humanitaria.

No obstante, clasificar de manera automatizada si un tweet describe una emergencia real o utiliza lenguaje metafórico (por ejemplo, *"The new album is fire"* o *"I'm drowning in homework"*) representa un reto significativo en el Procesamiento de Lenguaje Natural (NLP). El objetivo fundamental de este laboratorio es construir un sistema de minería de texto y aprendizaje automático capaz de discriminar entre tweets que reportan desastres reales (*target* = 1) y aquellos que no (*target* = 0).

2. Descripción del Conjunto de Datos y Análisis Exploratorio

El conjunto de datos utilizado corresponde a la competencia oficial de Kaggle *"Natural Language Processing with Disaster Tweets"*. Está compuesto por más de 10,800 observaciones distribuidas en conjuntos de entrenamiento (**train.csv**) y prueba (**test.csv**).


2.1. Estructura de Variables

El conjunto de entrenamiento contiene 7,613 filas y 5 columnas principales:

- **id**: Identificador numérico único de cada tweet.
- **keyword**: Palabra clave relevante asociada al tweet (puede contener valores nulos).
- **location**: Ubicación geográfica declarada por el autor (texto libre, alta tasa de valores nulos).
- **text**: Contenido textual íntegro del tweet.
- **target**: Etiqueta binaria de clasificación donde 1 denota un desastre real y 0 denota no desastre.

2.2. Distribución de Clases y Valores Faltantes

La Figura 1 ilustra la distribución de la variable objetivo y el porcentaje de valores nulos en cada variable. De los 7,613 tweets de entrenamiento, 4,342 (57.0 %) corresponden a mensajes que no describen desastres, mientras que 3,271 (43.0 %) corresponden a emergencias reales. Se observa un ligero desbalance, pero la proporción es adecuada para entrenamiento sin requerir técnicas severas de submuestreo o sobremuestreo.



(a) Distribución de la variable objetivo.

(b) Porcentaje de valores faltantes por atributo.

Figura 1: Distribución de clases y valores faltantes en el conjunto de entrenamiento.

Respecto a los valores nulos, la variable **location** presenta 2,533 valores faltantes (33.3 %), mientras que **keyword** contiene 61 nulos (0.8 %). La variable textual principal **text** y la variable objetivo **target** no contienen valores nulos.

2.3. Análisis de Palabras Clave (Keywords) y Longitud de Texto

El análisis de las palabras clave revela disparidades significativas entre clases. En la Figura 2 se aprecian las palabras clave más frecuentes para cada clase. En tweets de desastres reales predominan términos técnicos y operacionales como *derailment*, *wreckage*, *outbreak* y *typhoon*. En contraste, en tweets de no desastre aparecen términos con connotación coloquial o figurativa como *body %20bags*, *harm*, *armageddon* y *deluge*.




Figura 2: Top 10 palabras clave (*keywords*) en tweets de desastres vs no desastres.

Asimismo, en la Figura 3 se observa que los tweets de desastres reales tienden a poseer una mayor longitud promedio en caracteres y palabras en comparación con los tweets no relacionados a emergencias, lo cual sugiere un estilo de redacción más formal e informativo en reportes de noticias y advertencias oficiales.




Figura 3: Distribución de la cantidad de caracteres y palabras por tweet según categoría.

3. Limpieza y Preprocesamiento de los Datos

El lenguaje utilizado en Twitter se caracteriza por ruido sintáctico, presencia de hipervínculos, menciones de usuarios, abreviaciones y caracteres tipográficos no estándar. Para acondicionar el corpus textual se diseñó e implementó un pipeline secuencial de normalización mediante las librerías `re`, `string` y `NLTK` (*Natural Language Toolkit*):

1. **Conversión a minúsculas:** Homogeneización del espacio léxico para evitar duplicación de términos por distinción de mayúsculas.
2. **Eliminación de hipervínculos (URLs) y entidades HTML:** Expresiones regulares para remover enlaces (`https?://\S+|www\.\S+`) y secuencias escapadas (`&`, `<`, `>`).
3. **Manejo de menciones (@) y hashtags (#):** Las menciones de usuario (`@usuario`) se eliminan ya que corresponden a nombres propios específicos sin carga semántica generalizable. Por el contrario, los hashtags se descomponen para conservar el término interior (ejemplo: `#earthquake` → `earthquake`), dado que frecuentemente sintetizan el evento.

4. **Tratamiento diferenciado de números y código 911:** La mayoría de los números enteros corresponden a horas, coordenadas o cantidades irrelevantes. No obstante, el número **911** posee un significado crítico en situaciones de auxilio. Por ende, se implementó una regla que preserva explícitamente 911 (transformándolo en el token sintáctico **emergency911**) antes de suprimir el resto de los dígitos.
5. **Supresión de signos de puntuación y emoticones:** Se eliminan caracteres de puntuación y se remueven símbolos no ASCII / emoticones que no aportan a la semántica formal de clasificación.
6. **Filtrado de palabras vacías (*Stopwords*):** Se empleó el corpus de *stopwords* en inglés de NLTK, complementado con términos comunes de ruido en Twitter (*u, im, amp, via, dont, cant*).
7. **Lematización:** Reducción morfológica mediante *WordNetLemmatizer*, llevando las palabras a su raíz léxica (por ejemplo, *buildings* → *building*, *fires* → *fire*).

Tabla 1: Ejemplos de transformación mediante el pipeline de preprocesamiento.

Texto Original (Raw)	Texto Preprocesado (Cleaned)	Target
Our Deeds are the Reason of this #earthquake May ALLAH Forgive us all	deed reason earthquake may allah forgive	1
Forest fire near La Ronge Sask. Canada	forest fire near ronge sask canada	1
What a nice day to relax with a good book	nice day relax good book	0
Crying out: 911 emergency near downtown!	cry emergency911 emergency near downtown	1
Love this cross body bag so much!	love cross body bag much	0

4. Generación de N-gramas y Análisis de Frecuencias

4.1. Visualización mediante Nubes de Palabras (Word Clouds)

Para visualizar la prominencia relativa de los términos en cada subconjunto, se generaron nubes de palabras utilizando la librería *wordcloud*, como se presenta en la Figura 4.





Figura 4: Nubes de palabras para ambas categorías.

4.2. Unigramas y Bigramas más Frecuentes

En la Figura 5 se observan los unigramas y bigramas dominantes en cada categoría.



(a) Top 15 Unigramas.

(b) Top 15 Bigramas.

Figura 5: Comparación de Unigramas y Bigramas más frecuentes por clase.

4.3. Discusión sobre Vocabulario Compartido y la Necesidad de Contexto

El análisis comparativo de n-gramas revela elementos críticos para el modelado:

- **Términos predictivos de desastre:** Unigramas como *fire*, *california*, *suicide*, *disaster*, *police*, *kill*, *storm* y *flood* presentan una concentración preponderante en la clase de desastre real.
- **Ambigüedad y polisemia en unigramas:** Ciertas palabras como *fire*, *body*, *building*, *bomb* y *kill* aparecen con alta frecuencia en ambas clases. Por ejemplo, "*fire*" aparece 267 veces en desastres y 88 veces en no desastres (usado como jerga juvenil: "*this mixtape is fire*").
- **El rol esencial de los Bigramas y Trigramas:** Al incorporar bigramas, la ambigüedad se disipa drásticamente. Mientras que en desastres observamos colocaciones unívocas como *suicide bomber*, *california wildfire*, *severe thunderstorm* y *oil spill*, en la categoría no desastre encontramos combinaciones como *cross body*, *body bag* (asociado a carteras/moda), *liked video* y *reddit quarantine*. Esto demuestra concluyentemente que los modelos de clasificación deben alimentarse con representaciones que capturen n-gramas ($n \geq 2$) o ponderaciones TF-IDF que integren el contexto inmediato.

5. Modelos Preliminares de Clasificación

Para la entrega parcial se implementó y evaluó una suite de modelos de clasificación baseline sobre el corpus preprocesado.

5.1. Estrategia de Vectorización y Abordaje del Contexto

Para capturar la información sintáctica y el contexto local de las palabras, se utilizó la técnica de ponderación **TF-IDF** (*Term Frequency - Inverse Document Frequency*) configurada con:

- Rango de n-gramas: (1,2), integrando tanto unigramas como bigramas.
- Escalamiento logarítmico sublineal: `sublinear_tf = True`, que calcula $1 + \log(TF)$, amortiguando el impacto de palabras repetidas múltiples veces en un mismo tweet.
- Tamaño máximo de vocabulario: 10,000 características principales seleccionadas por frecuencia inversa de documento.

5.2. Algoritmos Evaluados

Se evaluaron cuatro algoritmos fundamentales con división estratificada de datos (80 % para entrenamiento y 20 % para validación, preservando la proporción original de clases):

1. **Multinomial Naive Bayes (MultinomialNB)**: Modelo probabilístico basado en el teorema de Bayes con supuesto de independencia condicional.
2. **Complement Naive Bayes (ComplementNB)**: Modificación adaptada para mitigar el sesgo hacia la clase mayoritaria.
3. **Regresión Logística (LogisticRegression)**: Modelo lineal con regularización L_2 ($C = 1,0$), optimizado para estimar probabilidades calibradas.
4. **Linear SVM (SGDClassifier)**: Clasificador de margen lineal entrenado mediante descenso de gradiente estocástico con función de pérdida logística.

6. Resultados y Evaluación Comparativa

6.1. Métricas de Rendimiento

La Tabla 2 resume las métricas cuantitativas obtenidas por cada modelo sobre el conjunto de validación independiente (1,523 tweets).

Tabla 2: Métricas de rendimiento de los modelos preliminares de clasificación.

Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Multinomial Naive Bayes	0.8201	0.8785	0.6743	0.7630	0.8731
Complement Naive Bayes	0.8142	0.8193	0.7278	0.7709	0.8731
Regresión Logística	0.8214	0.8435	0.7171	0.7752	0.8753
Linear SVM (SGD)	0.8201	0.8253	0.7370	0.7787	0.8747




Figura 6: Comparación de métricas de rendimiento en validación para los modelos preliminares.

6.2. Matrices de Confusión y Curvas ROC

En la Figura 7 se detallan las matrices de confusión de los cuatro modelos, y en la Figura 8 se exhiben las curvas ROC correspondientes.




Figura 7: Matrices de confusión de los modelos preliminares en el conjunto de validación.




Figura 8: Curvas ROC y valor de área bajo la curva (AUC) para los modelos preliminares.

6.3. Discusión de Resultados Preliminares

- **Regresión Logística:** Demuestra el desempeño global más equilibrado, alcanzando la mayor exactitud (82,14 %) y el mayor ROC-AUC (0,8753), con una alta precisión (84,35 %).

- **Multinomial Naive Bayes:** Presenta la precisión más elevada (87,85 %), lo que implica una tasa mínima de falsos positivos (únicamente 61 tweets no desastre clasificados erróneamente como desastre). No obstante, su recall (67,43 %) deja escapar un tercio de las alertas reales.
- **Linear SVM (SGD):** Obtiene el mayor F1-Score (0,7787) y la mejor sensibilidad/recall (73,70 %), resultando idóneo si la prioridad operativa consiste en no omitir desastres reales.

7. Conclusiones de la Entrega Parcial y Trabajo Futuro

1. El análisis exploratorio inicial permitió identificar la estructura del dataset, confirmando que no existen valores faltantes en la variable objetivo ni en el texto principal, y revelando diferencias estadísticas en la longitud de caracteres y vocabulario clave entre desastres reales y metáforas.
2. El pipeline de preprocesamiento logró normalizar de forma limpia el texto de redes sociales, eliminando URLs, menciones y puntuación, mientras que la regla ad-hoc para preservar el código de emergencia 911 protegió un token crítico para la predicción.
3. El estudio de n-gramas evidenció que los unigramas por sí solos presentan ambigüedad severa ante términos polisémicos (*fire*, *body*, *building*), mientras que los bigramas proporcionan el contexto discriminativo indispensable.
4. Los modelos preliminares basados en TF-IDF lograron superar el 82 % de exactitud y 0,875 de ROC-AUC en validación estratificada, estableciendo una línea base sólida.
5. **Pasos para la entrega final:** Incorporación de análisis de polaridad y sentimiento (TextBlob / VADER / SentiWordNet), ingeniería de características contextuales (variable de negatividad, longitudes, palabras en mayúsculas), ajuste de hiperparámetros (*Grid-SearchCV*), evaluación de modelos avanzados y desarrollo de la función interactiva de clasificación de tweets para usuarios finales.

Referencias

1. Jurafsky, D., & Martin, J. H. (2008). *Speech and Language Processing*. Stanford University.
2. Jurafsky, D., & Martin, J. H. (2014). *N-Grams*. *Speech and Language Processing*, pp. 2–7.
3. Feinerer, I., Hornik, K., & Meyer, D. (2008). *Text Mining Infrastructure in R*. *Journal of Statistical Software*, 25(5), 1–54.
4. Bird, S., Klein, E., & Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly Media.
5. Kaggle. (2020). *Natural Language Processing with Disaster Tweets*. Kaggle Competition Dataset.