

Laboratorio 5: Minería de Textos y Clasificación de Tweets sobre Desastres Naturales

Informe Final: Exploración, Preprocesamiento, Modelado, Clasificación Interactiva y Análisis de Sentimiento

Javier Eduardo España (23361)

Angel Esteban Esquit (23221)

Roberto José Barreda (23354)

*Departamento de Ciencias de la Computación, Universidad del Valle de Guatemala
CC3084 - Data Science*

30 de agosto de 2026

Resumen

En este informe se presenta el desarrollo exhaustivo del Laboratorio 5 sobre minería de textos, procesamiento de lenguaje natural (NLP) y análisis de sentimiento aplicado a la clasificación de tweets del conjunto de datos *Natural Language Processing with Disaster Tweets* de Kaggle. Se describe el análisis exploratorio de datos (EDA), identificando patrones en variables categóricas, longitudes de texto y tasas de datos faltantes. Se implementa un pipeline de preprocesamiento para redes sociales que normaliza el texto, elimina ruido y preserva información crítica (como el código de auxilio 911). Se realiza un análisis profundo de frecuencias y probabilidades de n-gramas (unigramas, bigramas y trigramas), demostrando la necesidad imperativa del contexto para resolver la ambigüedad de términos polisémicos. Se entrenan y comparan cuatro modelos de aprendizaje automático (*Multinomial Naive Bayes*, *Complement Naive Bayes*, *Regresión Logística* y *Linear SVM*), seleccionando la Regresión Logística como el mejor clasificador general ($ROC-AUC = 0,8753$) para alimentar una función interactiva que clasifica tweets nuevos sin preprocesar. Finalmente, se clasifica la polaridad de los tweets mediante léxicos de opinión y VADER, evaluando el impacto de los emoticones, respondiendo a interrogantes sobre los tweets extremos de sentimiento y determinando que los tweets de desastres reales son significativamente más negativos ($p = 2,004 \times 10^{-30}$). La incorporación de la variable de negatividad al vectorizador TF-IDF fue evaluada, demostrándose que no genera mejoras sustanciales debido a la redundancia con las características léxicas ya capturadas por TF-IDF.

1. Introducción

La proliferación masiva de plataformas de microblogging, en particular Twitter/X, ha transformado los canales de comunicación durante situaciones de emergencia. Ante eventos catastróficos como terremotos, inundaciones, incendios forestales o ataques terroristas, los usuarios publican advertencias, reportes y testimonios en tiempo real. Estos datos son de valor incalculable para organizaciones de rescate, agencias gubernamentales y medios de comunicación.

Sin embargo, filtrar y clasificar estos mensajes mediante sistemas automatizados presenta dificultades severas: los usuarios emplean frecuentemente lenguaje coloquial, sarcasmo, abreviaturas y metáforas (por ejemplo, *"This song is fire"* o *I'm drowning in exams*). El presente trabajo aborda de manera integral este problema mediante técnicas de minería de texto y aprendizaje supervisado, clasificando si un tweet describe un desastre real ($target = 1$) o si se trata de un mensaje ordinario ($target = 0$), complementando la investigación con análisis de sentimiento.

2. Descripción del Conjunto de Datos y Análisis Exploratorio

El conjunto de datos utilizado corresponde a la competencia oficial de Kaggle "*Natural Language Processing with Disaster Tweets*". Cuenta con más de 10,800 tweets divididos en entrenamiento (`train.csv`, 7,613 filas) y prueba (`test.csv`, 3,263 filas).


2.1. Estructura de Variables

El conjunto de entrenamiento incluye cinco variables:

- **id**: Identificador numérico único del tweet.
- **keyword**: Palabra clave asignada al tweet (puede ser nula).
- **location**: Ubicación geográfica declarada por el usuario (texto libre con alta tasa de nulos).
- **text**: Contenido textual original del mensaje.
- **target**: Variable binaria objetivo (1 = desastre real, 0 = no desastre).

2.2. Distribución de Clases y Datos Faltantes

La Figura 1 muestra la distribución del target y el porcentaje de valores faltantes por columna. De los 7,613 tweets de entrenamiento, 4,342 (57.0 %) corresponden a la clase 0 (no desastre) y 3,271 (43.0 %) a la clase 1 (desastre real). La proporción es balanceada y no requiere submuestreo artificial.



(a) Distribución de la variable objetivo.

(b) Porcentaje de valores faltantes por columna.

Figura 1: Distribución de clases y valores nulos en el conjunto de entrenamiento.

En cuanto a los valores faltantes, `location` presenta 2,533 nulos (33.27 %), mientras que `keyword` contiene 61 nulos (0.80 %). Las columnas `text` y `target` están 100 % completas.

2.3. Análisis de Palabras Clave y Longitud de Texto

El análisis de las palabras clave más frecuentes revela contrastes notorios entre clases. Como se aprecia en la Figura 2, en desastres reales predominan términos de riesgo físico objetivo (*derailment*, *wreckage*, *outbreak*, *typhoon*), mientras que en no desastres aparecen términos empleados de forma coloquial (*body bags*, *harm*, *armageddon*, *deluge*).




Figura 2: Top 10 palabras clave (*keywords*) en tweets de desastres vs no desastres.

Asimismo, en la Figura 3 se observa que los tweets de desastres reales tienden a poseer una mayor longitud en caracteres y palabras en comparación con los tweets no desastre, reflejando una redacción de tipo noticioso y descriptivo.




Figura 3: Distribución de la cantidad de caracteres y palabras según categoría.

3. Limpieza y Preprocesamiento de los Datos

El texto de Twitter presenta alta presencia de URLs, menciones de usuarios, signos tipográficos especiales, hashtags y contracciones. Se implementó un pipeline modular y reproducible mediante las librerías `re`, `string` y `NLTK`:

1. **Conversión a minúsculas:** Homogeneización del espacio léxico.
2. **Eliminación de URLs y entidades HTML:** Remoción de enlaces (`https?://\S+|www\.\S+`) y secuencias como `&`, `<`, `>`.
3. **Manejo de menciones (@) y hashtags (#):** Las menciones (`@usuario`) se descartan al ser identificadores individuales sin carga semántica generalizable. Por el contrario, los hashtags se procesan para conservar la palabra subyacente (`#earthquake` → `earthquake`).
4. **Tratamiento diferenciado de números y código 911:** La mayoría de los dígitos representan horas o métricas ruidosas; no obstante, el número **911** es el código universal de emergencia. Se implementó una regla que preserva **911** convirtiéndolo en el token sintáctico `emergency911` antes de suprimir el resto de los números.
5. **Supresión de signos de puntuación y emoticones:** Se eliminan signos de puntuación y caracteres no ASCII.

6. **Filtrado de palabras vacías (*Stopwords*):** Se utilizó la lista en inglés de NLTK complementada con tokens ruidosos de Twitter (*u, im, amp, via, dont, cant, like, get*).
7. **Lematización:** Reducción morfológica con `WordNetLemmatizer` para unificar formas plurales y conjugaciones a su lema base.

Tabla 1: Ejemplos de transformación mediante el pipeline de preprocesamiento.

Texto Original (Raw)	Texto Preprocesado (Cleaned)	Target
Our Deeds are the Reason of this #earthquake May ALLAH Forgive us all	deed reason earthquake may allah forgive	1
Forest fire near La Ronge Sask. Canada	forest fire near ronge sask canada	1
What a nice day to relax with a good book	nice day relax good book	0
Crying out: 911 emergency near downtown!	cry emergency911 emergency near downtown	1
Love this cross body bag so much!	love cross body bag much	0

4. Generación de N-gramas, Frecuencias y Probabilidades

4.1. Visualización con Nubes de Palabras (Word Clouds)

La Figura 4 presenta las nubes de palabras generadas con `wordcloud` para ambas clases. En desastres reales dominan términos como *fire*, *news*, *california*, *suicide*, *police*, *storm* y *killed*. En no desastres destacan *new*, *body*, *love*, *video*, *day* y *time*.




Figura 4: Nubes de palabras para desastres reales vs no desastres.

4.2. Frecuencias y Probabilidades de N-gramas

Se calcularon las frecuencias absolutas y probabilidades empíricas $P(w) = \frac{\text{count}(w)}{\sum \text{count}}$ para unigramas, bigramas y trigramas. La Tabla 2 resume los n-gramas más representativos.

Tabla 2: Top N-gramas con frecuencias y probabilidades empíricas por categoría.

Tipo	N-grama	Frecuencia	Probabilidad (P)
<i>Desastres Reales (target = 1):</i>			
Unigrama	fire	267	0.00929
Unigrama	news	141	0.00490
Unigrama	disaster	122	0.00424
Bigrama	suicide bomber	60	0.00235
Bigrama	northern california	41	0.00161
Bigrama	oil spill	38	0.00149
Trigrama	suicide bomber detonated	30	0.00130
Trigrama	northern california wildfire	29	0.00125
<i>No Desastres (target = 0):</i>			
Unigrama	new	170	0.00507
Unigrama	body	119	0.00355
Unigrama	video	102	0.00304
Bigrama	body bag	49	0.00161
Bigrama	cross body	39	0.00128
Bigrama	liked video	34	0.00112
Trigrama	cross body bag	24	0.00088
Trigrama	reddit quarantine offensive	19	0.00069




Figura 5: Comparación de Unigramas y Bigramas más frecuentes por categoría.

4.3. Vocabulario Compartido y la Necesidad Imperativa del Contexto

El análisis comparativo responde de forma directa a las preguntas 4 y 5 del laboratorio:

- **¿Qué palabras sirven mejor para clasificación?** Términos unívocos como *derailment*, *wildfire*, *suicide bombing*, *oil spill*, *richter* y *evacuate* son altamente discriminativos para desastres.
- **Ambigüedad de palabras compartidas:** Términos como *fire*, *body*, *building*, *burn* y *kill* aparecen en ambas categorías. Por ejemplo, *fire* aparece 267 veces en desastres (incendios reales) y 88 veces en no desastres (jerga musical y elogios). De igual forma, *body* aparece en desastres vinculado a víctimas mortales y en no desastres vinculado a moda (*cross body bag*).
- **¿Vale la pena explorar bigramas y trigramas?** Sí, es indispensable. Los bigramas eliminan la polisemia: *cross body* clasifica unívocamente a no desastre, mientras que *suicide bomber* o *california wildfire* clasifican unívocamente a desastre real.

5. Modelos de Clasificación y Abordaje del Contexto

5.1. Estrategia de Vectorización TF-IDF

Para capturar el contexto local se utilizó **TF-IDF** (*Term Frequency - Inverse Document Frequency*) con:

- Rango de n-gramas: (1, 2) para integrar simultáneamente unigramas y bigramas.
- Escalamiento sublineal: `sublinear_tf = True` ($1 + \log(TF)$) para amortiguar palabras repetitivas.
- Vocabulario: 10,000 características de mayor relevancia IDF.
- Partición estratificada: 80 % entrenamiento (6,090 tweets) y 20 % validación (1,523 tweets).

5.2. Modelos Evaluados

Se evaluaron cuatro clasificadores baseline de diversa naturaleza estadística:

1. **Multinomial Naive Bayes** (`MultinomialNB`): Modelo probabilístico basado en frecuencias relativas bajo independencia condicional.
2. **Complement Naive Bayes** (`ComplementNB`): Variante optimizada para datasets con ligero desbalance de clases.
3. **Regresión Logística** (`LogisticRegression`): Clasificador lineal con regularización L_2 ($C = 1,0$), generador de probabilidades continuas calibradas.
4. **Linear SVM** (`SGDClassifier`): Clasificador lineal de margen máximo optimizado con pérdida logística.

6. Resultados y Selección del Mejor Modelo

La Tabla 3 resume las métricas cuantitativas evaluadas sobre el conjunto de validación.

Tabla 3: Métricas de rendimiento de los modelos en validación estratificada.

Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Multinomial Naive Bayes	0.8201	0.8785	0.6743	0.7630	0.8731
Complement Naive Bayes	0.8142	0.8193	0.7278	0.7709	0.8731
Regresión Logística	0.8214	0.8435	0.7171	0.7752	0.8753
Linear SVM (SGD)	0.8201	0.8253	0.7370	0.7787	0.8747




Figura 6: Comparación de métricas de rendimiento en validación para los modelos.




Figura 7: Evaluación diagnóstica mediante matrices de confusión y curvas ROC.

6.1. Selección del Modelo Ganador

La **Regresión Logística** fue seleccionada como el mejor modelo para la tarea:

- Obtiene la mayor exactitud global (82,14 %) y el mayor ROC-AUC (0,8753).
- Mantiene un equilibrio superior entre precisión (84,35 %) y recall (71,71 %), produciendo un F1-Score sólido de 0,7752.
- Proporciona probabilidades probabilísticamente calibradas mediante la función sigmoide, permitiendo calibrar umbrales de decisión según la criticidad de la aplicación de emergencia.

7. Función de Clasificación de Tweets Interactiva

En cumplimiento del Ejercicio 7, se diseñó la función `classify_tweet(text, model, vectorizer)`, la cual clasifica nuevos tweets ingresados por el usuario **sin necesidad de preprocesamiento manual**.

El modelo final de Regresión Logística y el vectorizador TF-IDF fueron reentrenados sobre el 100 % del conjunto de entrenamiento limpio y serializados con `joblib` en `models/best_model_logreg.joblib` y `models/tfidf_vectorizer.joblib`. La Tabla 4 muestra la evaluación de la función sobre tweets de prueba representativos.

Tabla 4: Resultados de la función de clasificación sobre tweets nuevos sin preprocesar.

#	Tweet	Predicción	Prob. Desastre
1	Forest fire near La Ronge Sask. Canada	Desastre real	0.9178
2	This new album is fire, I can't stop listening to it!	No es un desastre	0.2641
3	BREAKING: Massive earthquake hits downtown, buildings collapsing #emergency	Desastre real	0.8776
4	I'm drowning in homework this week lol	No es un desastre	0.1354
5	Call 911 immediately, there's been an explosion at the factory	Desastre real	0.6573
6	Just had the best burger of my life at this new restaurant downtown	No es un desastre	0.2063

8. Análisis de Sentimiento y Clasificación de Polaridad

En el Ejercicio 8 se analizó la polaridad del texto mediante dos metodologías:

1. **Léxico de opinión de Hu y Liu:** Conteo explícito de palabras positivas (n_{pos}) y negativas (n_{neg}) del corpus léxico. Un tweet se clasifica en positivo si $n_{pos} > n_{neg}$, negativo si $n_{neg} > n_{pos}$, y neutro si $n_{pos} = n_{neg}$.
2. **Analizador VADER (*Valence Aware Dictionary and sEntiment Reasoner*):** Evaluación de intensidad compuesta ($compound\ score \in [-1, 1]$), clasificando como negativo ($compound < -0,05$), neutro ($-0,05 \leq compound \leq 0,05$) y positivo ($compound > 0,05$).




Figura 8: Distribución porcentual del sentimiento clasificado por categoría de tweet.

8.1. ¿Valdrá la pena dejar los emoticones y analizarlos?

Para responder cuantitativamente a la pregunta del Ejercicio 8, se realizó un experimento evaluando el impacto de conservar vs eliminar emoticones y emojis sobre los puntajes de sentimiento en todo el dataset de 7,613 tweets:

Tabla 5: Impacto cuantitativo de la presencia de emoticones sobre el puntaje VADER.

Métrica de Evaluación	Valor
Total de tweets en el corpus	7,613
Tweets que contienen emoticones o emojis	69 (0.91 %)
Tweets cuyo puntaje compuesto de sentimiento fue alterado	64 (0.84 %)
Diferencia media absoluta en el puntaje de todo el corpus	0.0030
Diferencia media absoluta en los tweets que sí tenían emoticon	0.3625

Conclusión sobre emoticones: Menos del 1 % de los tweets del dataset contienen emoticones, debido a que los tweets formales sobre emergencias y reportes climáticos casi nunca utilizan caritas o emojis. No obstante, en el subconjunto de tweets que sí los contienen, la diferencia de polaridad es sustancial ($\Delta = 0,3625$). Para tareas de análisis de sentimiento general en redes sociales es recomendable conservarlos y mapearlos a texto (ejemplo: :-) $\rightarrow$ smile), pero para la tarea específica de clasificar desastres reales, su exclusión en el pipeline principal simplifica el espacio vectorial sin degradar el rendimiento predictivo.

9. Hallazgos de Sentimiento y Preguntas de Investigación

9.1. Los 10 Tweets Más Negativos (Pregunta 9.1)

La Tabla 6 lista los 10 tweets con el puntaje VADER más negativo. Se observa que **8 de los 10 tweets (80 %)** corresponden a desastres reales ($target = 1$), vinculados a ataques suicidas, asesinatos, bombardeos y emergencias graves.

Tabla 6: Los 10 tweets más negativos del conjunto de datos.

ID	Texto del Tweet	Categoría	Compound
10689	wreck? wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck?	No desastre	-0.9883
9172	@Abu_Baraa1 Suicide bomber targets Saudi mosque at least 13 dead... This is ridiculous	Desastre real	-0.9686
9166	Suicide bomber kills 15 in Saudi security site mosque - A suicide bomber killed at least 15...	Desastre real	-0.9623
9137	19th Day Since 17-Jul-2015 – Nigeria: Suicide Bomb Attacks Killed 64 People; Blamed: Boko Haram	Desastre real	-0.9595
9159	17 killed in S Arabia mosque suicide bombing... suicide bomber attacked a mosque	Desastre real	-0.9552
4213	at the lake *sees a dead fish* me: poor little guy i wonder what happened idk maybe it drowned	No desastre	-0.9549
682	illegal alien released by Obama/DHS 4 times Charged With Rape & Murder of Santa Maria CA	Desastre real	-0.9538
2225	Bomb Crash Loot Riot Emergency Pipe Bomb Nuclear Chemical Spill Gas Ricin Leak Violence	Desastre real	-0.9524
9765	Bomb head? Explosive decisions dat produced more dead children than dead bodies trapped	Desastre real	-0.9500
9940	@cspan #Prez. Mr. President you are the biggest terrorist and trouble maker in the world	Desastre real	-0.9493

9.2. Los 10 Tweets Más Positivos (Pregunta 9.2)

La Tabla 7 lista los 10 tweets con el puntaje más positivo. En marcado contraste, **8 de los 10 tweets (80 %)** pertenecen a la categoría de no desastre ($target = 0$), conteniendo expresiones de entusiasmo, conciertos, humor o elogios.

Tabla 7: Los 10 tweets más positivos del conjunto de datos.

ID	Texto del Tweet	Categoría	Compound
10028	Check out 'Want Twister Tickets AND A VIP EXPERIENCE To See SHANIA? I would Love Love Love!	No desastre	0.9730
9345	@thoutaylorbrown I feel like accidents are just drawn to you but I'm happy you've survived...	No desastre	0.9564
8989	Today's storm will pass; let tomorrow's light greet you with a kiss. Bask in this loving warmth	Desastre real	0.9471
4541	@batfanuk we enjoyed the show today. Great fun. The emergency non evacuation was interesting.	No desastre	0.9423
4844	@batfanuk we enjoyed the show today. Great fun. The emergency non evacuation was interesting.	No desastre	0.9423
9710	Maaaaan I love Love Without Tragedy by @rihanna I wish she made the whole song	No desastre	0.9394
8994	Free Ebay Sniping RT? http://t.co/B231U11O1K Lumbar Extender Back Stretcher Excellent Condition!	No desastre	0.9376
3525	@Raishimi33 :) well I think that sounds like a fine plan where little derailment is possible :)	Desastre real	0.9356
1453	I'm not a Drake fan but I enjoy seeing him body-bagging people. Great marketing lol.	No desastre	0.9345
9386	@duchovbutt yeah we survived 9 seasons and 2 movies. Let's hope for the good. There's hope	No desastre	0.9344

9.3. ¿Son los tweets de desastres más negativos? (Pregunta 9.3)

Para responder de forma rigurosa, se comparó la negatividad (proporción de léxico negativo de VADER) y el puntaje compuesto entre ambas clases:

- **Desastres reales** ($target = 1$): Negatividad media = 0,1736, mediana = 0,1570, compound medio = -0,2646.
- **No desastres** ($target = 0$): Negatividad media = 0,1323, mediana = 0,0880, compound medio = -0,0606.

Dado que las distribuciones no siguen una normal Gaussiana (Figura 9), se aplicó la prueba no paramétrica de **Mann-Whitney U** (de una cola, H_1 : negatividad_{desastre} > negatividad_{no_desastre}), obteniendo un estadístico $U = 8,141,444,5$ y un p -valor de:

$$p = 2,004 \times 10^{-30} \ll 0,001$$

Conclusión: Se rechaza la hipótesis nula con altísima significancia estadística. Los tweets que reportan desastres reales son sistemáticamente y significativamente más negativos que los tweets no relacionados con desastres.




Figura 9: Comparación de la negatividad y densidad compound entre desastres reales y no desastres.

10. Incorporación de la Variable de Negatividad y Reentrenamiento

En cumplimiento del Ejercicio 10, se incorporó la variable continua de negatividad (**negatividad** $\in [0, 1]$) como una característica adicional concatenada a la matriz TF-IDF ($X_{full} = [X_{tfidf} \mid x_{neg}]$). Se reentrenaron los cuatro modelos bajo exactamente la misma partición estratificada.

La Tabla 8 y la Figura 10 comparan el desempeño con y sin la variable de negatividad.

Tabla 8: Comparación de modelos con y sin la variable de negatividad.

Conjunto	Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Sin negatividad	Multinomial NB	0.8201	0.8785	0.6743	0.7630	0.8731
Sin negatividad	Complement NB	0.8142	0.8193	0.7278	0.7709	0.8731
Sin negatividad	Regresión Logística	0.8214	0.8435	0.7171	0.7752	0.8753
Sin negatividad	Linear SVM (SGD)	0.8201	0.8253	0.7370	0.7787	0.8747
Con negatividad	Multinomial NB	0.8207	0.8802	0.6743	0.7636	0.8731
Con negatividad	Complement NB	0.8155	0.8199	0.7309	0.7728	0.8731
Con negatividad	Regresión Logística	0.8175	0.8381	0.7125	0.7702	0.8742
Con negatividad	Linear SVM (SGD)	0.8188	0.8327	0.7232	0.7741	0.8741




Figura 10: Comparación del F1-Score en los modelos con y sin la variable de negatividad.

10.1. ¿La inclusión de la variable mejoró los resultados? ¿En qué medida?

- **Impacto Cuantitativo:** La inclusión de la negatividad produjo variaciones marginales: en modelos probabilísticos (Naive Bayes) generó un incremento casi imperceptible ($\Delta F1 \approx +0,0007$ a $+0,0020$), mientras que en modelos lineales con regularización (Regresión Logística y Linear SVM) causó un leve decremento ($\Delta F1 \approx -0,0050$, $\Delta Accuracy \approx -0,39\%$).
- **Razón Fundamental de la Ausencia de Mejora:**
 1. **Redundancia Léxica:** La matriz TF-IDF con 10,000 características y n-gramas (1, 2) ya contiene las palabras de alta carga negativa (*killed*, *suicide*, *bomb*, *dead*, *fatalities*, *destroyed*). Por ende, la variable de negatividad no introduce información ortogonal nueva.
 2. **Bajo Poder Predictivo Aislado:** Como variable única, la negatividad sólo alcanza un $ROC-AUC = 0,5726$ (ligeramente superior al azar), ya que muchos tweets no

relacionados con desastres son altamente negativos (insultos, noticias de política, quejas).

3. **Escalamiento y Regularización:** Al concatenar un único valor continuo de negatividad junto a 10,000 coeficientes dispersos con regularización L_2 , el modelo asigna una penalización que no compensa la dispersión global del vocabulario.

11. Conclusiones Generales

1. El análisis exploratorio de datos confirmó que el conjunto de datos de tweets sobre desastres cuenta con un balance natural adecuado (57 % no desastre vs 43 % desastre real) y que la longitud de los mensajes informativos sobre emergencias es estadísticamente mayor que la de los mensajes casuales.
2. El preprocesamiento de texto es crucial: la normalización de hashtags y la preservación explícita del código de auxilio 911 permitieron retener tokens altamente informativos para el clasificador.
3. El análisis de n-gramas demostró que las representaciones basadas exclusivamente en unigramas sufren de alta ambigüedad semántica debido al uso figurativo y polisémico de términos como *fire* y *body*. La incorporación de bigramas (*suicide bomber*, *cross body*) aporta el contexto discriminativo necesario.
4. Entre los modelos evaluados, la **Regresión Logística con TF-IDF** demostró ser el mejor clasificador general ($Accuracy = 82,14\%$, $ROC-AUC = 0,8753$), sirviendo como base para la función interactiva `classify_tweet`.
5. El análisis de sentimiento confirmó que los tweets de desastres reales son significativamente más negativos que los tweets comunes ($p = 2,004 \times 10^{-30}$). Sin embargo, agregar la variable de negatividad al modelo no mejora su rendimiento predictivo debido a la redundancia de información con las características léxicas de TF-IDF.

Referencias

1. Jurafsky, D., & Martin, J. H. (2008). *Speech and Language Processing* (2nd ed.). Prentice Hall.
2. Jurafsky, D., & Martin, J. H. (2014). *N-Grams*. *Speech and Language Processing*, pp. 2–7.
3. Feinerer, I., Hornik, K., & Meyer, D. (2008). *Text Mining Infrastructure in R*. *Journal of Statistical Software*, 25(5), 1–54.
4. Hutto, C., & Gilbert, E. (2014). *VADER: A Parsimonious Rule-based Model for Sentiment Analysis of Social Media Text*. Eighth International AAAI Conference on Weblogs and Social Media.
5. Hu, M., & Liu, B. (2004). *Mining and summarizing customer reviews*. Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD-2004).
6. Bird, S., Klein, E., & Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly Media.
7. Kaggle. (2020). *Natural Language Processing with Disaster Tweets*. Kaggle Competition Dataset.